

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.896

Отчет об исследовательском проекте на тему:
Планирование для робота-манипулятора при помощи графа выпуклых оболочек
(промежуточный, этап 1)

Выполнил студент:

группы #БПМИ2410, 2 курса

Кривова Милана Дмитриевна

Проверен руководителем проекта:

Яковлев Константин Сергеевич

Доцент

Базовая кафедра ФИЦ ИУ РАН

Содержание

Аннотация	3
Ключевые слова	4
1 Введение и обзор литературы	4
2 Эксперименты	5
2.1 Эксперименты по построению выпуклых регионов	5
2.2 Эксперименты по планированию траекторий с использованием GCS	7
2.2.1 Планирование между удалёнными точками	7
2.2.2 Планирование между позициями на полках	8
Список литературы	9

Аннотация

В последние годы широкое распространение получили подходы к планированию движений манипуляторов, основанные на разбиении пространства конфигураций на граф выпуклых регионов и последующей оптимизации по этому графу. Ключевым узким местом таких методов является построение выпуклых областей в пространстве высокой размерности. Этот этап требует значительных вычислительных затрат, а полученные регионы не всегда обладают хорошими геометрическими свойствами, что приводит к ухудшению качества графа и увеличению времени поиска траектории.

В данной работе проводится исследование различных способов построения графа выпуклых оболочек в пространстве конфигураций манипулятора и анализируется их влияние на длину планируемого пути и время построения разбиения.

Ключевые слова

Планирование движений, робот-манипулятор, пространство конфигураций, выпуклые области, граф выпуклых оболочек

1 Введение и обзор литературы

Задача планирования движений для робототехнических манипуляторов в среде с препятствиями является актуальной и находит применение в таких областях, как промышленная робототехника и космическая робототехника. Данная задача активно исследуется на протяжении длительного времени, в результате чего было предложено множество различных подходов к её решению.

К классическим методам планирования относятся алгоритмы, основанные на случайном семплировании пространства конфигураций, такие как Rapidly-exploring Random Trees (RRT) [1] и Probabilistic Roadmaps (PRM) [2], которые широко применяются на практике благодаря своей универсальности и простоте реализации. Наряду с ними в последние годы получили развитие подходы, основанные на машинном обучении [3], направленные на ускорение поиска траекторий или аппроксимацию сложных проверок столкновений.

Одним из современных направлений в области планирования движений являются оптимизационные методы, в рамках которых задача планирования формулируется как задача оптимизации с ограничениями [4]. В частности, в ряде работ предлагается представлять пространство конфигураций в виде графа выпуклых множеств (Graph of Convex Sets, GCS) [5], по которому далее осуществляется поиск оптимальной траектории с использованием методов выпуклой оптимизации. Такой подход позволяет эффективно сочетать дискретный выбор последовательности регионов и непрерывную оптимизацию внутри каждого выпуклого множества.

Эффективность методов, основанных на графе выпуклых множеств, в значительной степени определяется качеством разбиения пространства конфигураций на выпуклые области. Построение таких областей в пространстве высокой размерности является вычислительно сложной задачей, особенно в случае манипуляторов с большим числом степеней свободы. В работе C-IRIS [6] предлагается метод построения сертифицированных выпуклых регионов без коллизий в пространстве конфигураций с использованием выпуклой оптимизации и сумм квадратов, однако вычислительная сложность подобных подходов быстро возрастает с увеличением размерности задачи.

В более поздних работах рассматриваются приближённые методы разбиения пространства конфигураций, направленные на уменьшение числа выпуклых регионов и ускорение их построения. В частности, в [7] основывается на покрытии графов видимости кликами, предлагается аппроксимировать пространство конфигураций с помощью небольшого числа выпуклых оболочек, что позволяет существенно сократить вычислительные затраты

по сравнению с итеративным наращиванием регионов.

Несмотря на предложенные подходы, задача выбора и сравнения способов построения графа выпуклых оболочек остаётся открытой. В частности, остаётся не до конца исследованным влияние различных методов разбиения пространства конфигураций на качество планируемых траекторий и вычислительную эффективность алгоритмов планирования, что и является предметом настоящей работы.


2 Эксперименты

В данном разделе представлены результаты экспериментального исследования, направленного на анализ качества разбиения пространства конфигураций на выпуклые регионы, а также на оценку влияния этого разбиения на эффективность планирования траекторий с использованием графа выпуклых множеств (GCS).


2.1 Эксперименты по построению выпуклых регионов

В первой серии экспериментов исследовалось влияние способа генерации начальных точек для алгоритма IRIS на качество разбиения пространства конфигураций. Качество разбиения напрямую влияет на эффективность поиска в задачах GCS, поскольку узкие, вытянутые или слабо связанные выпуклые регионы приводят к ухудшению сходимости алгоритмов оптимизации.


Для построения выпуклых регионов использовалась реализация алгоритма IRIS из симулятора Drake. В качестве тестовой платформы применялась модель манипулятора KUKA iiwa с 7 степенями свободы. Эксперименты проводились в трёх сценах различной сложности: сцена с одной полкой, сцена с двумя параллельными полками и сцена с тремя полками, расположенными вокруг манипулятора (Рис. 2.1).



(a) Манипулятор и одна полка



(b) Манипулятор и две параллельные полки



(c) Манипулятор и три полки вокруг него

Рис. 2.1: Экспериментальные сцены, использованные для построения IRIS-регионов

Для каждой сцены выполнялись независимые запуски алгоритма IRIS с числом начальных точек 10, 20, 30 и 50 (Рис. 2.2). В ходе экспериментов измерялись время построения выпуклых регионов, количество изолированных регионов, а также качество покрытия пространства конфигураций. Оценка покрытия выполнялась методом Монте-Карло на основе 500 случайных конфигураций. Покрытие определялось как доля конфигураций, принадлежащих хотя бы одному выпуклому региону.




Рис. 2.2: Случайно сгенерированные начальные точки для алгоритма IRIS

Таблица 2.1: Анализ покрытия IRIS-регионами для различных сцен

Scene	Seeds	Isolation (%)	Coverage (%)	IRIS Time (s)
Single Shelf	10	0.0	67.0	63
Single Shelf	20	0.0	67.8	156
Single Shelf	30	0.0	76.2	180
Single Shelf	50	0.0	83.0	319
Two Shelves	10	0.0	66.3	97
Two Shelves	20	0.0	72.2	218
Two Shelves	30	0.0	75.2	256
Two Shelves	50	0.0	82.2	430
Three Shelves	10	0.0	40.2	348
Three Shelves	20	0.0	47.2	413
Three Shelves	30	0.5	51.5	691
Three Shelves	50	0.5	60.2	1299

Результаты показывают, что увеличение числа начальных точек приводит к росту

покрытия пространства конфигураций, однако при этом существенно возрастает время построения выпуклых регионов, особенно для сцен со сложной геометрией. Кроме того, равномерная случайная генерация начальных точек приводит к недостаточному покрытию узких и геометрически сложных областей сцены, в частности зон вблизи полок.

2.2 Эксперименты по планированию траекторий с использованием GCS

Во второй серии экспериментов исследовалось влияние качества разбиения пространства конфигураций на результаты планирования траекторий. Для улучшения покрытия областей сложной геометрии был введён параметр `shelf_ratio`, определяющий долю начальных точек для IRIS, генерируемых вблизи полок. Во всех экспериментах использовалось значение `shelf_ratio = 0.3`.

Качество планирования оценивалось по двум метрикам: длина траектории и время решения. Были рассмотрены два сценария: планирование между максимально удалёнными точками в пространстве конфигураций и планирование между позициями на полках.

2.2.1 Планирование между удалёнными точками

Таблица 2.2: Результаты планирования между удалёнными точками

Scene	Seeds	Success	Path Length	Solve Time (s)
Single Shelf	10	3/3	10.31 ± 0.20	0.007
Single Shelf	20	3/3	11.29 ± 1.00	0.012
Single Shelf	30	3/3	10.73 ± 0.62	0.008
Single Shelf	50	3/3	11.03 ± 0.46	0.007
Two Shelves	10	3/3	12.93 ± 1.25	0.029
Two Shelves	20	3/3	11.81 ± 1.44	0.010
Two Shelves	30	3/3	11.00 ± 0.65	0.014
Two Shelves	50	3/3	11.06 ± 1.22	0.008
Three Shelves	10	3/3	9.77 ± 0.51	0.019
Three Shelves	20	3/3	10.52 ± 1.59	0.021
Three Shelves	30	3/3	10.30 ± 0.42	0.013
Three Shelves	50	3/3	10.99 ± 0.76	0.027

Во всех сценах была достигнута 100% успешность планирования. Время решения остается малым, что подтверждает эффективность двухэтапного подхода с использованием предварительного поиска пути в графе регионов.

2.2.2 Планирование между позициями на полках

Таблица 2.3: Результаты планирования между позициями на полках

Scene	Seeds	Success	Success (%)	Path Length	Solve Time (s)
Single Shelf	10	3/3	100	0.48	0.010
Single Shelf	20	1/3	33	0.07	0.002
Single Shelf	30	1/3	33	0.18	0.002
Single Shelf	50	1/3	33	0.07	0.001
Two Shelves	10	0/15	0	–	–
Two Shelves	20	1/15	7	0.01	0.000
Two Shelves	30	10/15	67	1.02	0.006
Two Shelves	50	0/15	0	–	–
Three Shelves	10	3/21	14	0.11	0.002
Three Shelves	20	11/21	52	0.56	0.001
Three Shelves	30	12/21	57	0.70	0.003
Three Shelves	50	15/21	71	1.07	0.010

Эксперименты в сложных геометриях показали, что увеличение плотности выпуклых регионов критично для успешного планирования. При этом результаты остаются нестабильными для некоторых сцен, что указывает на необходимость дальнейших исследований по улучшению стратегии разбиения пространства конфигураций.

Список литературы

- [1] LaValle S. M. Rapidly-Exploring Random Trees: A New Tool for Path Planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 1998.
- [2] Karaman S., Frazzoli E. Sampling-based algorithms for optimal motion planning // The International Journal of Robotics Research. — 2011. — Vol. 30. — P. 846–894.
- [3] Kalashnikov D., Irpan A., Pastor P., Ibarz J., Herzog A., Jang E., Quillen D., Holly E., Kalakrishnan M., Vanhoucke V., Levine S. QT-Opt: Scalable Deep Reinforcement Learning for Vision-Based Robotic Manipulation [Электронный ресурс] // Proceedings of the 2nd Conference on Robot Learning (CoRL 2018). — Zürich, Switzerland, 2018.
- [4] Zucker M., Ratliff N., Dragan A. D., Pivtoraiko M., Klingensmith M., Dellin C. M., Bagnell J. A., Srinivasa S. S. CHOMP: Covariant Hamiltonian Optimization for Motion Planning // The International Journal of Robotics Research. — 2013. — Vol. 32. — P. 1164–1193.
- [5] Marcucci T., Umenberger J., Parrilo P. A., Tedrake R. Shortest Paths in Graphs of Convex Sets // SIAM Journal on Optimization. — 2021.
- [6] Werner P., Cohn T., Jiang R. H., Seyde T., Simchowicz M., Tedrake R., Rus D. Faster Algorithms for Growing Collision-Free Convex Polytopes in Robot Configuration Space [Электронный ресурс] // arXiv preprint arXiv:2410.12649. — 2024.
- [7] Werner P., Amice A., Marcucci T., Rus D., Tedrake R. Approximating Robot Configuration Spaces with Few Convex Sets using Clique Covers of Visibility Graphs // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — Yokohama, Japan, 2024. — P. 10359–10365.