

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.896

Отчет об исследовательском проекте на тему:
Планирование для робота-манипулятора при помощи графа выпуклых оболочек
(промежуточный, этап 1)

Выполнил студент:

группы #БПМИ2410, 2 курса

Кривова Милана Дмитриевна

Проверен руководителем проекта:

Яковлев Константин Сергеевич

Доцент

Базовая кафедра ФИЦ ИУ РАН

Содержание

Аннотация	3
Ключевые слова	4
1 Введение	4
2 Обзор работ в предметной области	4
2.1 Sampling-based подходы	4
2.2 Optimization-based подходы	5
2.3 Learning-based подходы	6
3 Обзор литературы	7
4 Эксперименты	7
4.1 Эксперименты по построению выпуклых регионов	8
4.2 Эксперименты по планированию траекторий с использованием GCS	10
4.2.1 Планирование между удалёнными точками	10
4.2.2 Планирование между позициями на полках	11
Список литературы	14

Аннотация

В последние годы широкое распространение получили подходы к планированию движений манипуляторов, основанные на разбиении пространства конфигураций на граф выпуклых регионов и последующей оптимизации по этому графу. Ключевым узким местом таких методов является построение выпуклых областей в пространстве высокой размерности. Этот этап требует значительных вычислительных затрат, а полученные регионы не всегда обладают хорошими геометрическими свойствами, что приводит к ухудшению качества графа и увеличению времени поиска траектории.

В данной работе проводится исследование различных способов построения графа выпуклых оболочек в пространстве конфигураций манипулятора и анализируется их влияние на длину планируемого пути и время построения разбиения.

Ключевые слова

Планирование движений, робот-манипулятор, пространство конфигураций, выпуклые области, граф выпуклых оболочек

1 Введение

Планирование движений для робототехнических манипуляторов в среде с препятствиями является важной задачей для промышленной робототехники. Требуется построить траекторию в пространстве конфигураций, удовлетворяющую ограничениям на коллизии и движения робота, при этом практическая применимость определяется как качеством траектории, так и вычислительной стоимостью планирования.

В работе рассматривается семейство методов, основанных на представлении свободного пространства в виде графа выпуклых множеств (Graph of Convex Sets, GCS), и анализируется влияние способов построения данного представления на качество решений и вычислительные затраты при планировании движений манипулятора. Задача выбора и сравнения способов построения графа выпуклых оболочек остаётся открытой. В частности, не до конца исследованным является влияние различных методов разбиения пространства конфигураций на качество планируемых траекторий и вычислительную эффективность алгоритмов планирования, что и является предметом настоящей работы.

2 Обзор работ в предметной области

Задача планирования движений в пространствах высокой размерности является широко исследуемой задачей на протяжении последних десятилетий и имеет множество подходов. Основные из них можно разделить на следующие группы:

- 1 Sampling-based подходы
- 2 Optimization-based подходы
- 3 Learning-based подходы

Каждый из перечисленных подходов обладает собственными преимуществами и ограничениями, что приводит к активному развитию гибридных методов, сочетающих идеи нескольких парадигм для повышения масштабируемости и надёжности планирования в сложных сценариях.

2.1 Sampling-based подходы

Методы планирования движений, основанные на случайном семплировании конфигурационного пространства, получили широкое распространение благодаря своей применимости в пространствах высокой размерности и наличию формальных теоретических свойств.

К числу базовых алгоритмов данного класса относятся PRM (Probabilistic Roadmaps) [2] и RRT (Rapidly Exploring Random Trees) [1], которые заложили основу для большинства современных sampling-based подходов.

В последующих работах было предложено множество модификаций указанных алгоритмов, направленных на повышение вычислительной эффективности и качества получаемых решений. В частности, в широко используемых программных библиотеках, таких как OMPL (Open Motion Planning Library) [8], реализованы различные варианты алгоритма RRT, включая RRT* [2], обладающий свойством асимптотической оптимальности за счёт переоптимизации локальных соединений, а также RRT-Connect [9], использующий двунаправленный рост деревьев для ускорения поиска допустимого пути. Ключевым теоретическим свойством sampling-based методов является *probabilistic completeness*, означающая, что при существовании допустимого решения вероятность того, что алгоритм не сможет его найти, стремится к нулю по мере увеличения числа сэмплов [11], [12].

Для алгоритмов семейства RRT* дополнительно показана асимптотическая оптимальность, то есть сходимости стоимости найденного пути к оптимальному решению при неограниченном росте числа сэмплов. Более строгий анализ условий выполнения данных гарантий, а также уточнение исходного доказательства асимптотической оптимальности RRT* представлены в работе [10].

При этом следует отметить, что указанные теоретические гарантии носят асимптотический характер и не обеспечивают нахождение решения за конечное время, что может существенно ограничивать практическую эффективность sampling-based методов в задачах планирования движений для манипуляторов в пространствах высокой размерности.

2.2 Optimization-based подходы

Несмотря на наличие формальных теоретических гарантий, sampling-based методы обладают рядом практических ограничений, связанных с высокой вычислительной стоимостью и ограниченным качеством получаемых траекторий. В частности, такие методы, как правило, находят лишь геометрически допустимый путь, который требует дополнительной постобработки для обеспечения гладкости и соответствия кинематическим ограничениям манипулятора. Эти недостатки послужили мотивацией для развития optimization-based подходов к планированию движений.

Optimization-based методы формулируют задачу планирования движений как задачу оптимизации в непрерывном пространстве траекторий, где необходимо минимизировать

функционал стоимости при наличии ограничений, отражающих требования к коллизиям, гладкости траектории и ограничениям на движения робота [17]. В рамках данного подхода траектория обычно параметризуется конечным числом переменных, а поиск решения осуществляется с использованием численных методов оптимизации [18].

К числу наиболее известных optimization-based алгоритмов относятся CHOMP [13], STOMP [14] и TrajOpt [15], которые получили широкое распространение в задачах планирования движений для робототехнических манипуляторов. Данные методы позволяют напрямую учитывать требования к гладкости и динамическим характеристикам движения, что делает их особенно привлекательными для практического применения. Однако в задачах оптимизации качество найденного решения сильно зависит от начальной инициализации траектории, что подробно обсуждается в [16].

Существенным отличием optimization-based подходов от sampling-based методов является отсутствие глобальных гарантий нахождения решения в случае его существования. В отличие от probabilistic completeness, характерной для sampling-based алгоритмов, optimization-based методы обеспечивают лишь локальную оптимальность и могут сходиться к недопустимым или субоптимальным решениям [15].

2.3 Learning-based подходы

Learning-based подходы к планированию движений используют методы машинного обучения для повышения эффективности классических sampling-based и optimization-based алгоритмов. В отличие от традиционных методов, такие подходы, как правило, не предоставляют строгих теоретических гарантий корректности и сходимости, однако позволяют существенно сократить время планирования и повысить масштабируемость в пространствах высокой размерности [19].

Наиболее распространённым сценарием применения learning-based методов является их использование в качестве вспомогательных компонентов планировщика. В частности, обучаемые модели применяются для генерации информативных сэмплов и направленного расширения деревьев поиска, что позволяет ускорить sampling-based планирование без нарушения его базовых свойств [20] [21].

Другим направлением является использование нейронных моделей для приближённого предсказания допустимости соединений между конфигурациями, а также для обучения структурированных представлений пространства конфигураций, что снижает вычислительные затраты при построении траекторий [22] [23].

Несмотря на достигнутые успехи, learning-based подходы остаются чувствительными к качеству обучающих данных и демонстрируют ограниченную обобщающую способность за пределами распределения обучающей выборки. В связи с этим на практике наибольший интерес представляют гибридные методы, в которых learning-based компоненты используются совместно с классическими алгоритмами планирования для сохранения надёжности и интерпретируемости решений [21] [23].

3 Обзор литературы

Классические подходы к планированию движений характеризуются различными компромиссами между вычислительной сложностью и качеством решений. Одним из направлений, сочетающих дискретный выбор структуры решения с непрерывной оптимизацией, является подход Graphs of Convex Sets (GCS).

Подход Graphs of Convex Sets (GCS) [5] формулирует задачу планирования движений как поиск пути на графе, вершины которого соответствуют выпуклым подмножествам допустимого пространства, а рёбра задают возможность перехода между ними. В рамках данного подхода дискретный выбор последовательности регионов сочетается с непрерывной оптимизацией внутри каждого выпуклого множества.

Ключевой проблемой при применении GCS является построение набора выпуклых регионов, лежащих целиком в свободном от коллизий пространстве конфигураций. В работах, основанных на методе IRIS [6], предлагается строить большие выпуклые области без коллизий с использованием выпуклой оптимизации [24]. Развитие данного подхода в виде C-IRIS позволяет получать сертифицированные выпуклые регионы в пространстве конфигураций манипуляторов, однако вычислительная сложность таких методов быстро возрастает с увеличением размерности задачи [25].

В более поздних работах рассматриваются приближённые и масштабируемые методы построения GCS, направленные на уменьшение числа выпуклых регионов и ускорение их построения. В [7], предлагается аппроксимировать пространство конфигураций с использованием покрытий графа видимости кликами.

4 Эксперименты


В данном разделе представлены результаты экспериментального исследования, направленного на анализ качества разбиения пространства конфигураций на выпуклые регио-

ны, а также на оценку влияния этого разбиения на эффективность планирования траекторий с использованием графа выпуклых множеств (GCS).


4.1 Эксперименты по построению выпуклых регионов

В первой серии экспериментов исследовалось влияние способа генерации начальных точек для алгоритма IRIS на качество разбиения пространства конфигураций. Качество разбиения напрямую влияет на эффективность поиска в задачах GCS, поскольку узкие, вытянутые или слабо связанные выпуклые регионы приводят к ухудшению сходимости алгоритмов оптимизации.


Для построения выпуклых регионов использовалась реализация алгоритма IRIS из симулятора Drake. В качестве тестовой платформы применялась модель манипулятора KUKA iiwa с 7 степенями свободы. Эксперименты проводились в трёх сценах различной сложности: сцена с одной полкой, сцена с двумя параллельными полками и сцена с тремя полками, расположенными вокруг манипулятора (Рис. 2.1).



(a) Манипулятор и одна полка



(b) Манипулятор и две параллельные полки



(c) Манипулятор и три полки вокруг него

Рис. 4.1: Экспериментальные сцены, использованные для построения IRIS-регионов

Для каждой сцены выполнялись независимые запуски алгоритма IRIS с числом начальных точек 10, 20, 30 и 50 (Рис. 2.2). В ходе экспериментов измерялись время построения выпуклых регионов, количество изолированных регионов, а также качество покрытия пространства конфигураций. Оценка покрытия выполнялась методом Монте-Карло на основе 500 случайных конфигураций. Покрытие определялось как доля конфигураций, принадлежащих хотя бы одному выпуклому региону.




Рис. 4.2: Случайно сгенерированные начальные точки для алгоритма IRIS

Таблица 4.1: Анализ покрытия IRIS-регионами для различных сцен

Scene	Seeds	Isolation (%)	Coverage (%)	IRIS Time (s)
Single Shelf	10	0.0	67.0	63
Single Shelf	20	0.0	67.8	156
Single Shelf	30	0.0	76.2	180
Single Shelf	50	0.0	83.0	319
Two Shelves	10	0.0	66.3	97
Two Shelves	20	0.0	72.2	218
Two Shelves	30	0.0	75.2	256
Two Shelves	50	0.0	82.2	430
Three Shelves	10	0.0	40.2	348
Three Shelves	20	0.0	47.2	413
Three Shelves	30	0.5	51.5	691
Three Shelves	50	0.5	60.2	1299

Результаты показывают, что увеличение числа начальных точек приводит к росту покрытия пространства конфигураций, однако при этом существенно возрастает время построения выпуклых регионов, особенно для сцен со сложной геометрией. Кроме того, равномерная случайная генерация начальных точек приводит к недостаточному покрытию узких и геометрически сложных областей сцены, в частности зон вблизи полок.

4.2 Эксперименты по планированию траекторий с использованием GCS

Во второй серии экспериментов исследовалось влияние качества разбиения пространства конфигураций на результаты планирования траекторий. Для улучшения покрытия областей сложной геометрии был введён параметр `shelf_ratio`, определяющий долю начальных точек для IRIS, генерируемых вблизи полок. Во всех экспериментах использовалось значение `shelf_ratio = 0.3`.

Качество планирования оценивалось по двум метрикам: длина траектории и время решения. Были рассмотрены два сценария: планирование между максимально удалёнными точками в пространстве конфигураций и планирование между позициями на полках.

4.2.1 Планирование между удалёнными точками

Таблица 4.2: Результаты планирования между удалёнными точками

Scene	Seeds	Success	Path Length	Solve Time (s)
Single Shelf	10	3/3	10.31 ± 0.20	0.007
Single Shelf	20	3/3	11.29 ± 1.00	0.012
Single Shelf	30	3/3	10.73 ± 0.62	0.008
Single Shelf	50	3/3	11.03 ± 0.46	0.007
Two Shelves	10	3/3	12.93 ± 1.25	0.029
Two Shelves	20	3/3	11.81 ± 1.44	0.010
Two Shelves	30	3/3	11.00 ± 0.65	0.014
Two Shelves	50	3/3	11.06 ± 1.22	0.008
Three Shelves	10	3/3	9.77 ± 0.51	0.019
Three Shelves	20	3/3	10.52 ± 1.59	0.021
Three Shelves	30	3/3	10.30 ± 0.42	0.013
Three Shelves	50	3/3	10.99 ± 0.76	0.027

Во всех сценах была достигнута 100% успешность планирования. Время решения остается малым, что подтверждает эффективность двухэтапного подхода с использованием предварительного поиска пути в графе регионов.

4.2.2 Планирование между позициями на полках

Таблица 4.3: Результаты планирования между позициями на полках

Scene	Seeds	Success	Success (%)	Path Length	Solve Time (s)
Single Shelf	10	3/3	100	0.48	0.010
Single Shelf	20	1/3	33	0.07	0.002
Single Shelf	30	1/3	33	0.18	0.002
Single Shelf	50	1/3	33	0.07	0.001
Two Shelves	10	0/15	0	—	—
Two Shelves	20	1/15	7	0.01	0.000
Two Shelves	30	10/15	67	1.02	0.006
Two Shelves	50	0/15	0	—	—
Three Shelves	10	3/21	14	0.11	0.002
Three Shelves	20	11/21	52	0.56	0.001
Three Shelves	30	12/21	57	0.70	0.003
Three Shelves	50	15/21	71	1.07	0.010

Эксперименты в сложных геометриях показали, что увеличение плотности выпуклых регионов критично для успешного планирования. При этом результаты остаются нестабильными для некоторых сцен, что указывает на необходимость дальнейших исследований по улучшению стратегии разбиения пространства конфигураций.

Список литературы

- [1] LaValle S. M. Rapidly-Exploring Random Trees: A New Tool for Path Planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 1998.
- [2] Karaman S., Frazzoli E. Sampling-based algorithms for optimal motion planning // The International Journal of Robotics Research. — 2011. — Vol. 30. — P. 846–894.
- [3] Kalashnikov D., Irpan A., Pastor P., Ibarz J., Herzog A., Jang E., Quillen D., Holly E., Kalakrishnan M., Vanhoucke V., Levine S. QT-Opt: Scalable Deep Reinforcement Learning for Vision-Based Robotic Manipulation [Электронный ресурс] // Proceedings of the 2nd Conference on Robot Learning (CoRL 2018). — Zürich, Switzerland, 2018.
- [4] Zucker M., Ratliff N., Dragan A. D., Pivtoraiko M., Klingensmith M., Dellin C. M., Bagnell J. A., Srinivasa S. S. CHOMP: Covariant Hamiltonian Optimization for Motion Planning // The International Journal of Robotics Research. — 2013. — Vol. 32. — P. 1164–1193.
- [5] Marcucci T., Umenberger J., Parrilo P. A., Tedrake R. Shortest Paths in Graphs of Convex Sets // SIAM Journal on Optimization. — 2021.
- [6] Werner P., Cohn T., Jiang R. H., Seyde T., Simchowitz M., Tedrake R., Rus D. Faster Algorithms for Growing Collision-Free Convex Polytopes in Robot Configuration Space [Электронный ресурс] // arXiv preprint arXiv:2410.12649. — 2024.
- [7] Werner P., Amice A., Marcucci T., Rus D., Tedrake R. Approximating Robot Configuration Spaces with Few Convex Sets using Clique Covers of Visibility Graphs // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — Yokohama, Japan, 2024. — P. 10359–10365.
- [8] Sucan I. A., Moll M., Kavraki L. E. The Open Motion Planning Library // IEEE Robotics & Automation Magazine. — 2012. — Vol. 19, No. 4. — P. 72–82.
- [9] Kuffner J. J., LaValle S. M. RRT-Connect: An efficient approach to single-query path planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 2000. — Vol. 2. — P. 995–1001.
- [10] Solovey K., Janson L., Schmerling E., Frazzoli E., Pavone M. Revisiting the Asymptotic Optimality of RRT // Proc. IEEE Int. Conf. on Robotics and Automation (ICRA). — 2020. — C. 2189–2195.

- [11] Kavraki L. E., Svestka P., Latombe J.-C., Overmars M. H. Probabilistic roadmaps for path planning in high-dimensional configuration spaces // IEEE Transactions on Robotics and Automation. — 1996. — T. 12, № 4. — C. 566–580.
- [12] Kleinbort M., Solovey K., Littlefield Z., Bekris K. E., Halperin D. Probabilistic Completeness of RRT for Geometric and Kinodynamic Planning With Forward Propagation // IEEE Robotics and Automation Letters. — 2019. — Vol. 4, No. 2.
- [13] Ratliff N., Zucker M., Bagnell J. A., Srinivasa S. CHOMP: Gradient optimization techniques for efficient motion planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 2009. — P. 489–494.
- [14] Kalakrishnan M., Chitta S., Theodorou E., Pastor P., Schaal S. STOMP: Stochastic trajectory optimization for motion planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 2011. — P. 4569–4574.
- [15] Schulman J., Ho J., Lee A., Bradlow H., Awwal I., Abbeel P. Finding locally optimal, collision-free trajectories with sequential convex optimization // Proceedings of Robotics: Science and Systems (RSS). — 2013.
- [16] Toussaint M. Robot trajectory optimization using approximate inference // Proceedings of the International Conference on Machine Learning (ICML). — 2015.
- [17] Betts J. T. Practical Methods for Optimal Control and Estimation Using Nonlinear Programming // SIAM. — 2010.
- [18] Dragan A. D., Ratliff N. D., Srinivasa S. S. Manipulation planning with goal sets using constrained trajectory optimization // Proc. IEEE Int. Conf. on Robotics and Automation (ICRA). — 2011. — C. 4582–4588.
- [19] Elbanhawi M., Simic M. Sampling-Based Robot Motion Planning: A Review // IEEE Access. — 2014. — Vol. 2. — P. 56–77.
- [20] Ichter B., Harrison J., Pavone M. Learning Sampling Distributions for Robot Motion Planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 2018. — P. 7087–7094.
- [21] Faust A., Oslund K., Francis A., Paxton C., Lu Y., Chen C., Liu J., Kew J., Fiser M., Meier F. PRM-RL: Long-Range Robotic Navigation Tasks by Combining Reinforcement Learning and

- Sampling-Based Planning // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 2018. — P. 5113–5120.
- [22] Qureshi A. H., Yip M. C. Motion Planning Networks // Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). — 2019. — P. 211–217.
- [23] Wang J., Zhang X., Yu H., Xu K. Neural RRT: Learning-Based Optimal Path Planning // IEEE Robotics and Automation Letters. — 2020. — Vol. 5, No. 2. — P. 2260–2267.
- [24] Deits R., Tedrake R. Computing Large Convex Regions of Obstacle-Free Space Through Semidefinite Programming // Proceedings of the Workshop on the Algorithmic Foundations of Robotics (WAFR). — 2014.
- [25] Petersen M., Tedrake R. Growing Convex Collision-Free Regions in Configuration Space using Nonlinear Programming // arXiv:2303.14737. — 2023.